

Natural Language Processing with Disaster Tweets

Loshmanov Egor 24942



Суть задачи

"The sky above the port was the color of television, tuned to a dead channel." — слово несёт катастрофический образ, но реальной катастрофы нет.

"Forest fire near La Ronge Sask. Canada" — реальное событие.

Цель: построить модель бинарной классификации, которая по тексту твита определяет, связан ли он с реальной катастрофой.

- `target = 1` — твит о реальной катастрофе
- `target = 0` — твит не о катастрофе

Метрика оценки: F1-score

Датасет

Файлы

Файл	Описание	Строк
train.csv	Твиты с метками	7 613
test.csv	Твиты без меток (для предсказания)	3 263
sample_submission.csv	Пример формата ответа	—

Поля датасета

Поле	Описание	Пропуски в train
id	Уникальный идентификатор	0
text	Текст твита	0
keyword	Ключевое слово из твита	61 (0.8%)
location	Местоположение автора	2 533 (33%)
target	Метка класса (только в train)	0

Распределение классов

Класс	Количество	Доля
0 — не катастрофа	4 342	57%
1 — катастрофа	3 271	43%

Использованные подходы

#	Подход	Метрика	Score
1	BoW + LogReg	val F1	0.7367
2	TF-IDF + SVM	val F1	0.7300
3	TF-IDF + LogReg	val F1	0.7462
4	Word2Vec + LogReg	val F1	0.6777
5	DistilBERT	public LB	0.82991
6	Ensemble (DistilBERT + BERTweet)	public LB	0.83787
7	Ensemble + self-cleaning	public LB	0.84094
8	Ensemble + RoBERTa + self-cleaning	public LB	0.84584



Natural Language Processing with Disaster Tweets

Submit Prediction

...

Overview Data Code Models Discussion **Leaderboard** Rules Team Submissions

You have not submitted any predictions yet. Try and improve your score!					
52	PrenolanMunsamy		0.84584	6	2mo
53	AmLear		0.84584	2	2mo
54	Egor Loshmanov		0.84584	12	15h
 Your Best Entry! Your most recent submission scored 0.84584, which is an improvement over your previous score of 0.84094. Great job! Tweet this					
55	JMoonxai		0.84523	8	17d
56	Татьяна Ильиных		0.84492	10	14d


Возможные улучшения

#	Подход	Ожидаемый Δ F1
1	Iterative self-cleaning (новый проход по 00Fs v3)	+0.002–0.005
2	Добавить DeBERTa-v3-base в ensemble	+0.002–0.004
3	BERTweet-large вместо base	+0.002–0.003
4	Multi-seed ensemble (3 seeds на каждую модель)	+0.001–0.003

Стек технологий

- transformers (HuggingFace) — DistilBERT, BERTweet, RoBERTa
- torch — обучение моделей, multi-GPU
- pandas, numpy — работа с данными
- scikit-learn — метрики, KFold, классические модели
- NLTK, gensim — лемматизация, Word2Vec
- matplotlib — визуализация
- tqdm — прогресс-бары

презентация окончена



спасибо за внимание